联邦学习的加权方式

一、联邦学习的权重可以分成哪些类型？

严格来说，并不存在一个所有论文都统一采用的固定分类数量。为了梳理文献，我建议把权重分成下面七种研究思路。

1. 按样本量加权（Sample-size weighting）

$$\alpha_i = \frac{n_i}{\sum_j n_j}$$

依据：客户端本轮使用的训练样本数量。

目标：让每条训练样本在全局经验风险中获得相同权重。

这是 FedAvg、FedSGD 等经典算法的常见设置。

2. 按客户端均等加权（Uniform client weighting）

$$\alpha_i = \frac{1}{|S_t|}$$

依据：客户端数量，而不是每个客户端拥有多少样本。

目标：让每个客户端对聚合模型具有相同的名义影响力。

适用于更重视客户端平等参与的设计，但不等价于对所有数据样本进行均匀加权。

3. 按数据质量或代表性加权（Quality / representativeness weighting）

$$\alpha_i = \frac{q_i}{\sum_j q_j}$$

依据：数据质量、标签可靠性、数据覆盖度、与目标分布的匹配程度等。

目标：不让大量低质量、重复性强或代表性不足的数据主导模型。

注意：q_i 必须有合理的定义和估计方法，不能因为客户端训练准确率低就直接判定其数据质量差。

4. 按贡献度加权（Contribution-based weighting）

$$\alpha_i = \frac{c_i}{\sum_j c_j}$$

依据：客户端对整体模型性能、任务效用或特定指标的边际贡献。

例如，可以借助 Shapley 值或验证集上的性能变化来估计贡献。

目标：让对目标任务更有价值的更新获得更高的聚合权重。相关研究已将贡献评分与鲁棒聚合结合起来。

https://www.google.com/s2/favicons?domain=https://doi.org&sz=32

5. 按可信度或鲁棒性加权（Trust / robustness weighting）

$$\alpha_i = \frac{r_i}{\sum_j r_j}$$

依据：更新是否异常、历史行为、信誉评分、梯度相似性或异常检测结果等。

目标：降低可疑更新的影响，缓解恶意模型更新或异常参与者带来的风险。

但可信度加权不等于密码学验证，也不保证一定能够识别投毒攻击。

https://www.google.com/s2/favicons?domain=https://doi.org&sz=32

6. 按公平性或任务重要性加权（Fairness / task-aware weighting）

$$\alpha_i = \frac{f_i}{\sum_j f_j}$$

依据：客户端覆盖的稀缺群体、重要区域、关键任务或公平性指标。

目标：避免数据量大的客户端长期主导模型，使小样本客户端或重要但稀少的任务得到合理关注。

这类设计可能有意偏离标准的样本量加权目标，因此需要明确其优化目标。

https://www.google.com/s2/favicons?domain=https://doi.org&sz=32

7. 自适应或动态加权（Adaptive / dynamic weighting）

$$\alpha_i^{(t)} = \frac{s_i^{(t)}}{\sum_j s_j^{(t)}}$$

依据：随训练轮次变化的相似度、损失、更新稳定性、时效性、不确定性或历史贡献等综合评分。

目标：让聚合权重随着系统状态或训练阶段调整，而不是始终固定。

需要注意，设备计算能力和网络质量本身通常更直接地用于客户端选择、调度或异步更新处理；只有算法明确将这些因素转换成聚合系数时，才属于这里讨论的聚合加权。

上面第 3–7 类给出的公式是统一的示意形式，不是某个特定算法的原始公式。实际论文中，评分函数

的定义可能完全不同。相关聚合综述也把传统样本数量加权与自适应、注意力、鲁棒及公平性导向的聚合策略区分讨论。

https://www.google.com/s2/favicons?domain=https://link.springer.com&sz=32

二、为什么不能只看数据量?

假设有三个参与联邦学习的客户端:

客户端	本地样本量	数据情况
UAV-A	10,000	大量重复观测，主要覆盖同一区域
UAV-B	3,000	数据较少，但覆盖关键区域
UAV-C	2,000	样本量少，传感器偶尔出现异常

使用标准的样本量权重时:

$$\alpha_A = \frac{10000}{15000} = 0.667$$

$$\alpha_B = \frac{3000}{15000} = 0.200$$

$$\alpha_C = \frac{2000}{15000} = 0.133$$

这意味着 UAV-A 的更新占据约三分之二的聚合权重。

但是，若目标是协同感知或定位，大量重复观测不一定代表更高的信息价值；UAV-B 虽然数据较少，却可能覆盖了其他 UAV 无法观测的关键区域。

因此:

- 如果目标是拟合全部客户端数据构成的总体分布，样本量加权是自然的基线。
- 如果目标是提高关键区域的定位精度，就需要考虑任务重要性或区域覆盖。
- 如果某些观测存在异常，就需要考虑质量评估或鲁棒聚合。
- 如果目标是避免某些客户端长期被忽略，就需要研究公平性。

后面几种机制不是天然优于 FedAvg，而是针对不同的目标函数和系统需求作出不同的权重设计。